

Dados disponíveis para o algoritmo de trending

Inventário do que é coletado por notícia, do que é agregado por acontecimento (cluster), de como o trend score usa esses dados hoje e do material disponível para evolução da fórmula. Gerado em 31/08/2026 a partir do código em produção (v0.1).

1. O que puxamos de cada notícia (Article)

CAMPO	DE ONDE VEM	OBSERVAÇÃO
title / normalized_title	todas as fontes	limpo de HTML e do sufixo " - Veículo"
description	RSS sempre; Google News quase nunca ¹ ; GDELT nunca	até 600 caracteres
url / canonical_url	todas	sem parâmetros de tracking; no Google News é o redirect deles
source_name / source_domain	GN (tag <source>), GDELT (domain), RSS (config)	domínio real sempre disponível
published_at	pubDate (GN/RSS), seendate (GDELT)	UTC; RSS sem data usa collected_at
collected_at	pipeline	horário da coleta
original_query	a busca ou feed que achou o item	ex.: "TSE", "rss:G1"
collector	google_news / gdel / rss	origem do item
language / country	query (GN), API (GDELT), config (RSS)	pt/en no escopo atual
possible_vertical	hint da query / categoria da fonte	sugestão ao router, não decisão
authority_score	sources.yaml (domain_authority)	0-100; domínio desconhecido = 50

¹ O summary do Google News geralmente só repete o título — é descartado na normalização.

2. O que agregamos por acontecimento (StoryCluster)

O trending opera no cluster (grupo de matérias sobre o mesmo evento), não na matéria isolada:

- **source_count** — número de matérias no cluster
- **unique_domain_count** + lista de domínios — diversidade de veículos
- **earliest / latest_published_at** — início e fim da janela de cobertura (span)
- **language_distribution** — contagem por idioma (ex.: pt:3, en:2)
- **possible_verticals** — contagem dos hints das queries que acharam o evento
- **query_count** — quantas buscas distintas encontraram o evento
- + todos os Articles completos (títulos, fontes, autoridades, datas)

3. Como o trend score usa isso hoje (config/ranking.yaml)

trend = 100 × soma(peso × sinal) — fórmula determinística, explícita e testada; o LLM não participa.

SINAL	PESO	DEFINIÇÃO
source_diversity	28%	domínios únicos, saturando em 6
recency	22%	decaimento exponencial da ÚLTIMA publicação (meia-vida de 9h)
velocity	12%	(matérias – 1) / horas do span, normalizado em 2 matérias/hora
authority	18%	média das 3 maiores autoridades de domínio do cluster

SINAL	PESO	DEFINIÇÃO
query_spread	8%	número de buscas distintas que acharam o evento (satura em 3)
novelty	12%	1 – similaridade com títulos selecionados nos últimos 3 runs

Depois: $\text{final_score} = \text{blend}(\text{trend}, \text{editorial})$ – penalidade de verificação, com pesos por vertical (entretenimento 0.45/0.55 · política 0.30/0.70 · fatos 0.20/0.80).

4. Material para evoluir a fórmula

4.1 · Já temos e NÃO usamos (custo zero — só mudar a fórmula)

- **language_distribution** — cobertura em pt E en sinaliza escala global do evento; hoje ignorado.
- **Overlap de collectors** — evento achado por Google News + GDELT + RSS ao mesmo tempo é sinal de robustez; hoje basta 1.
- **earliest_published_at** — só usamos o latest (recência). O par earliest/latest permite medir ACELERAÇÃO: evento antigo ganhando matérias novas ('esquentando') vs. furo recente parado.
- **Posição no feed do Google News** — o próprio GN rankeia os resultados e descartamos a ordem no parse. É um trending score de graça.
- **Entidades salientes** — já extraídas para o clustering; permitem medir 'entidade quente' (mesma pessoa/assunto em N clusters do dia).

4.2 · Fraquezas conhecidas da fórmula atual

- **velocity ruidosa** em clusters pequenos: 2 matérias em 30 min = taxa altíssima.
- **diversity satura em 6**: no run real houve clusters com 34 domínios valendo o mesmo que 6.
- **recency olha a última publicação**: cluster grande sempre tem alguém recente; assunto requentado com follow-up ganha recência de graça.
- **dedupe de syndication apaga cópias idênticas** — que são sinal de relevância de agência (trade-off documentado).

4.3 · Fácil de puxar com as fontes atuais (pouco código, sem API key)

- **GDELT TimelineVol** — série temporal de volume de cobertura por query: velocidade e aceleração REAIS em vez da aproximação por span.
- **GDELT socialimage** — a API já indica se a matéria tem imagem social (proxy de compartilhável).
- **RSS: tags, autor e imagem** (media:content) — vêm no feed e são ignorados hoje.

4.4 · Exigiria fontes novas (fase futura)

- Sinais sociais reais (X/Reddit/Instagram) e **Google Trends** (interesse de busca).
- Texto completo das matérias (scraping) — melhora embeddings/clustering e extração de entidades.
- **Feedback loop do próprio Instagram** (spec §60): performance real dos posts alimentando o score — o sinal mais valioso a médio prazo.

Como testar mudanças: os pesos são YAML (config/ranking.yaml) e cada run salva o debug completo (sinais por cluster, decisões de seleção) em data/runs/ — dá para reprocessar fórmulas novas contra runs passados sem gastar API. Implementação: src/processing/ranking.py · modelos: src/models.py.